

RAG 技術完整指南

Retrieval-Augmented Generation | 檢索增強生成

AI 應用

LLM

向量資料庫

知識管理

企業 AI

本文件深入介紹

RAG（檢索增強生成）技術的核心概念、運作流程、實際應用場景與最佳實踐，適合作為企業導入 AI 知識庫的參考範本。

第一章 什麼是 RAG？

RAG (Retrieval-Augmented Generation, 檢索增強生成) 是一種結合「資訊檢索」與「大型語言模型生成」的 AI 架構。它讓 LLM 在回答問題前，先從外部知識庫中找到相關資料，再將資料整合進提示詞 (Prompt)，從而生成更準確、更有來源根據的答案。

☒ 傳統 LLM vs. RAG 比較

比較項目	傳統 LLM	RAG 架構
知識來源	訓練資料 (靜態)	外部知識庫 (動態)
知識更新	需重新訓練	即時更新文件即可
幻覺問題	較高機率	大幅降低
可追溯性	無法追蹤來源	附帶文件來源引用
適用情境	通用對話	企業知識、專業領域

☒ RAG 核心優勢

即時更新

無需重新訓練
即可更新知識

可追溯性

回答附帶來源
提升可信度

成本效益


減少幻覺現象
降低運算成本

資料隱私

企業文件不須
上傳至雲端

第二章 RAG 運作流程

RAG 系統包含兩大核心階段：離線的「索引建立」與線上的「檢索生成」。下圖展示完整的資料流向：




▲ 圖 2-1 RAG 端對端資料流程圖

☒ 流程步驟詳解

- ① 文件前處理
將 PDF、Word、網頁等原始文件切割成適當大小的文字區塊 (Chunk)，常見策略包含固定長度分割、語意分割與遞迴分割。
- ② 向量嵌入
使用 Embedding 模型 (如 text-embedding-3-small) 將每個 Chunk 轉換為高維度向量，捕捉語意資訊。
- ③ 向量儲存
將向量存入向量資料庫 (ChromaDB、Pinecone、Qdrant 等)，建立可快速查詢的索引結構。
- ④ 問題檢索
使用者提問後，問題同樣被嵌入為向量，再以餘弦相似度或 BM25 混合檢索，找出最相關的 Top-K 個 Chunk。
- ⑤ 提示詞組合
將檢索到的 Chunk 與原始問題組合成增強提示詞，指示 LLM 僅根據提供資料回答。
- ⑥ 生成回答
LLM 根據增強提示詞生成最終回答，並可附上文件來源引用，提升答案可追溯性。

第三章 Embedding 向量嵌入技術

Embedding（嵌入）是將文字轉換為數字向量的技術核心。語意相近的文字在向量空間中彼此距離較近，使機器能進行語意相似度計算而非單純關鍵字匹配。




▲ 圖 3-1 文件向量化流程示意

常用 Embedding 模型比較

模型名稱	提供商	維度數	特點
text-embedding-3-small	OpenAI	1,536	高效低成本，適合大量文件
text-embedding-3-large	OpenAI	3,072	高精準度，適合複雜語意
bge-m3	BAAI	1,024	多語言支援，開源免費
nomic-embed-text	Nomic	768	本地部署，隱私保護
mxbai-embed-large	MixedBread	1,024	MTEB 榜單高分模型

第四章 文件切割（Chunking）策略

切割策略直接影響 RAG 的檢索品質。Chunk 太大會稀釋關鍵資訊；Chunk 太小則缺乏語境。需依據文件類型與應用場景選擇最適合的策略。



☑ 實踐建議 一般文件建議從 512 tokens + 50 tokens 重疊開始，再根據測試結果調整。RAG 評估指標可使用 RAGAS 框架（Faithfulness、Answer Relevancy、Context Recall）量化品質。

第五章 實際應用場景

企業內部知識庫

將公司規章、SOP、技術文件、FAQ 建成 RAG 系統，員工可用自然語言查詢，大幅降低人工查找成本。

- 人資政策查詢
- 技術文件搜尋
- 產品規格比對

客戶服務自動化

整合產品手冊、退換貨政策等文件，AI 客服能給出精準且有來源的答案，減少客服人員負擔。

- 售後服務問答
- 故障排除指引
- 訂單狀態查詢

法律與合規分析

輸入合約、法規文件，讓 LLM 協助條款摘要、風險識別與合規檢查，提升法務效率。

- 合約條款審閱
- 法規比對分析
- 合規風險標記

醫療知識輔助

整合醫療指引、藥典、臨床研究，為醫護人員提供循證依據，輔助臨床決策支援系統。

- 藥物交互查詢
- 診療指引參考
- 病歷摘要生成

第六章 導入最佳實踐

01 文件品質優先

進出（GIGO）原則同樣適用於 RAG。確保輸入文件結構清晰、內容準確、版本最新，是系統品質的根本保障。

02 混合檢索策略

單純向量檢索對關鍵字的敏感度較低，建議結合 BM25 關鍵字檢索與向量語意檢索，採用 RRF（倒數排名融合）演算法合併結果，提升召回率。

03 重排序（Reranking）

初步檢索後，使用 Cross-Encoder 重排序模型（如 bge-reranker）對候選 Chunk 進行精確相關性排序，僅將 Top-3 送入 LLM，節省 Context 空間。

04 評估與監控

上線後持續使用 RAGAS 等框架評估系統品質，追蹤 Faithfulness（忠實度）、Answer Relevancy（相關性）、Context Precision（精確率）等指標。

05 Prompt 工程

明確指示 LLM「僅根據提供的參考資料回答」、「若無相關資料請如實告知」，可有效減少幻覺並提升回答可信度。

推薦技術棧

類別	開源方案	商業方案
向量資料庫	ChromaDB、Qdrant、Weaviate	Pinecone、Zilliz Cloud
Embedding	bge-m3、nomic-embed	OpenAI text-embedding-3
LLM	Llama 3、Mistral、Qwen	GPT-4o、Claude 3.5
RAG 框架	LangChain、LlamaIndex	AnythingLLM、Dify
評估工具	RAGAS、TruLens	Langfuse、Phoenix

結語

RAG 技術正在快速演進，從基礎的「Naive RAG」到「Advanced RAG」再到「Modular RAG」，每一代架構都在解決前一代的局限性。無論是小型新創還是大型企業，RAG 都提供了一條低成本、高效益的 AI 知識管理路徑。

本文件所介紹的概念、流程與最佳實踐，可作為您設計與部署 RAG 系統的起點。建議從小規模的概念驗證（PoC）開始，逐步擴展至生產環境，並持續根據評估指標優化各個環節。

RAG	LLM	Embedding	向量資料庫	Chunking
Retriever	Reranking	RAGAS	LangChain	Prompt Engineering
ChromaDB	語意搜尋	知識庫	幻覺消除	企業 AI